Lívia Caroline Rodrigues Pereira - 2024024003

TAREFA 5: OLS 1D

· Letras a, b e c no código (imagens no fim desse arquivo)

d)

	PREDITORES			PREDIÇÃO
	X_1	X_2 ...	X_n	y
1	7	a	0.8	4
2	8	b	0.5	2
⋮	⋮	⋮	⋮	⋮
n	10	a	0.2	8

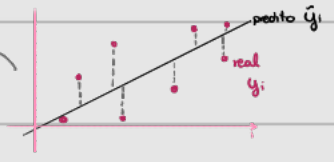
variáveis independentes | variável dependente

→ Supondo Relação linear, queremos usar as variáveis X para prever y_i.

↳ Em cada indivíduo i de 1:n

Precisamos descrever relação → 1d: $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 X + \varepsilon$

Precisamos de β's que minimizem a distância $y_{predito} \leftrightarrow y_{real}$.



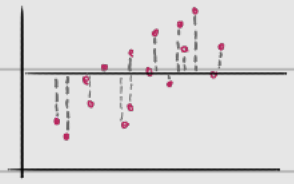
Nossa distância é medida pelo resíduo do erro

$e_i = y_i - \hat{y}_i$

Ou seja, precisamos minimizar esse erro.

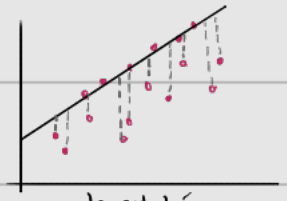
→ MÉTODO DE MÍNIMOS QUADRADOS ORDINÁRIOS

O método OLS busca assim minimizar a Soma dos Quadrados dos resíduos, ou SSR: $\sum_{i=1}^{n} [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)]^2$



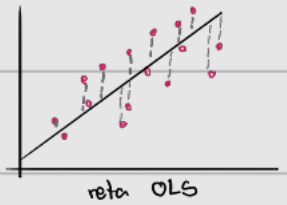
modelo ingênuo ($\hat{y} = \bar{y}$)

As distâncias são a dispersão



ajuste arbitrário

Apesar de passear por vários pontos, fica enviesado



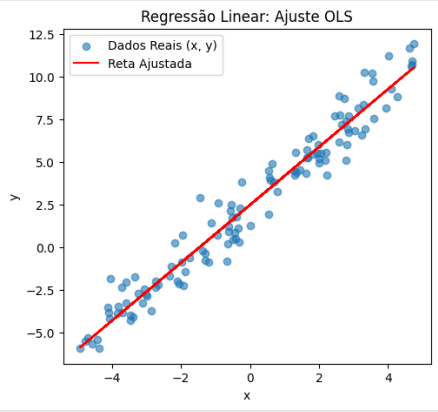
reta OLS

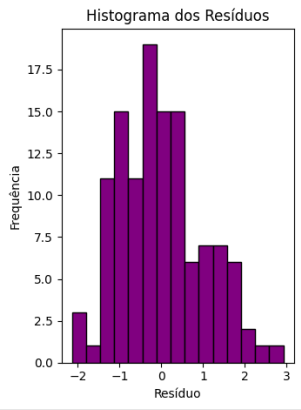
Centraliza o erro, buscando estar tão perto quanto possível de todos os pontos

e) O esquema ilustra o raciocínio geométrico e matemático da Regressão Linear 1D, a partir dos dados brutos e avançando até à otimização preditiva (com OLS). A representação gráfica busca evidenciar que o objetivo do modelo não é acertar (interceptar) a maior quantidade de pontos, mas sim diminuir ao máximo o erros

resíduos, ou distâncias verticais, garantindo o melhor ajuste global. Embora a solução fechada OLS forneça um ajuste eficiente, a sua forma quadrática penaliza erros maiores também de forma quadrática, tornando a reta extremamente sensível a outliers, que podem enviesar a regressão.

Entregas (Gráficos e tabelas)





Métrica	Valor
MSE	1.0155
MAE	0.8025
R^2	0.9548

TAREFA 2: Ridge Regression

- Letras a, b, c e d no código (imagens no fim desse arquivo)

e)

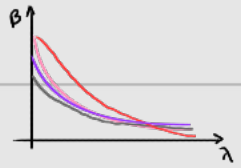
Anteriormente, vimos OLS. Mas ele tem limitações ⚠

→ Imagine que tenho p=2 mas n=3. Posso formar infinitas retas! ∞

→ Nos casos de $n < p$ e nos casos de multicolinearidade, não consigo usar OLS bem!

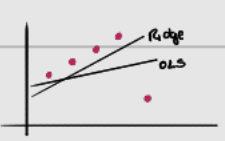
Tenho $x_i = x_j$ e perco uma dimensão. É como tentar equilibrar os dados em uma gangorra instável

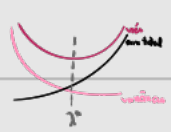
Temos então uma possível solução: penalização. A Regressão Ridge introduz uma nova função objetivo $J = SSR + \lambda \sum_{j=1}^{p} \beta_j^2$. Assim, o "peso" de cada β é alterado por λ, e Ridge "aceita mais" erro de treino para ganhar estabilidade (OLS minimiza puro erro de treino), ao segurar os βs para não crescerem demais



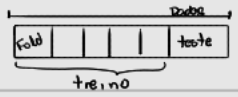
OLS tem βs rígidos que mudam a reta fácil com os dados, tem alta variância → Validação Cruzada:

Ao corrigir isso, Ridge introduz um aumento no viés





Escolher bem λ!



Para cada λ, realiza K treino+teste:



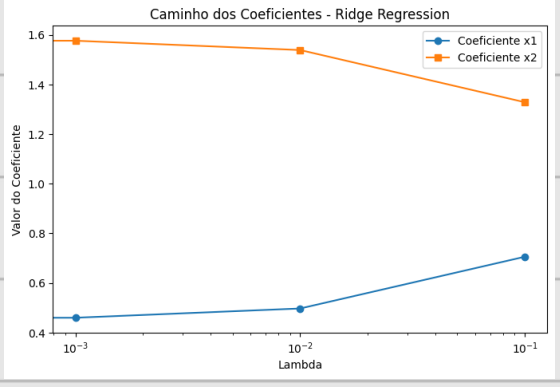
2. Uso treino para calcular βs
3. Armazeno erro da validação

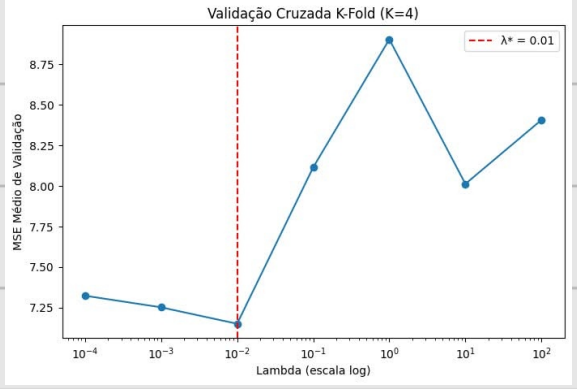
Para cada λ, calculo a média dos K erros
O λ com menor erro médio → λ^*

Uso λ^* em 100% dos dados originais treino + teste do início

b) A regularização L2 estabiliza os coeficientes em cenários de multicolinearidade ao impor uma penalização proporcional ao quadrado das suas magnitudes. Isto impede o comportamento instável e a variância infinita do método clássico (OLS), que atribuiria pesos extremos e opostos à variáveis correlacionadas. Além disso, na alta dimensionalidade ($n < p$), X^TX não tem posto completo (singular, sem inversa); ao adicionar λI vou deslocar todos os autovalores para maiores que zero, transformando a matriz em definida positiva (garantindo inversa).

Entregas (gráficos e tabelas)





Métrica	Valor Final (Ridge com λ*)
MSE	0.1766
MAE	0.358
R^2	0.9735